



医学图像计算青年研讨会
Medical Image Computing Seminar



第十三届医学图像计算青年研讨会
13TH MEDICAL IMAGE COMPUTING SEMINAR

基础模型时代的 通用CT图像恢复

从专用去噪到通用恢复 · From Denoising to Foundation Restoration

褚玥潭 · 阿卜杜拉国王科技大学 · MD安德森癌症研究中心


CONTENTS / 目录

01| CT成像基础与图像退化

02| CT图像恢复算法回顾

03| 从专用模型到通用表征

04| CT 恢复基础模型




CONTENTS / 目录

01| CT成像基础与图像退化

02| CT图像恢复算法回顾

03| 从专用模型到通用表征

04| CT 恢复基础模型



CT成像：现代医学诊疗中的核心工具

健康体检

疾病预防与健康管理

疾病筛查

肺癌、冠心病早期发现

临床诊断

高分辨率、快速成像

治疗规划


靶区定位、手术导航

疗效检测

病灶随访与定量测量

预后评估

复发预测与生存分析



01| CT成像基础与图像退化

CT成像链路：投影采集与图像重构

$$I(r) = I_0 \cdot \exp\left[-\int \sigma(r(t)) dt\right]$$

01

X-ray Source

多角度发射 X 射线，管电流决定光子通量

02

Attenuation

射线穿过人体，被组织吸收衰减

03

Projection

探测器记录各角度的线积分

04

Sinogram

多角度投影组成 sinogram 数据集

05


Reconstruct

将投影反演为断层图像

06

CT Image

HU 值图像，供临床诊断和 AI 下游任务



Backprojection: CT图像重建的基础思想

将不同角度采集到的一维投影数据，沿原扫描路径“铺回”图像空间，逐步叠加形成物体的二维结构估计。

$$\begin{aligned} g(x, y) &= \mathcal{B}p_{\theta}(z) \\ &= \frac{1}{2\pi} \int_{\theta=0}^{2\pi} p_{\theta}(x \cdot \cos \theta + y \cdot \sin \theta) d\theta \end{aligned}$$

STEP 01 Projection

一维积分

单角度投影只能提供沿射线方向的积分信息，无法定位结构

STEP 02 Backprojection

多角度叠加

多角度反投影叠加，逐步恢复空间结构，但有低频模糊

STEP 03 Filtering

频域加权滤波

高频滤波校正模糊

STEP 04 Reconstruction

重建算法

利用FBP、迭代重构等算法重建CT图像

低剂量与快速扫描： 临床需求推动非理想 成像

图像退化不是偶然问题，而是临床需求、硬件限制和扫描策略共同作用的结果。

辐射剂量与图像质量之间存在根本性权衡：降低剂量 → 光子数减少 → 噪声增大 → 图像质量下降

$$I(r) = I_0 \cdot \exp \left[-\int \sigma(r(t)) dt \right]$$

控制辐射剂量

降低儿童、孕妇、长期随访患者累积辐射剂量

提高扫描效率

急诊、术中实时成像场景对速度要求高

特殊人群适配

危重患者、不能配合者需稀疏采样或有限角扫描


大规模筛查

肺癌低剂量筛查项目的普及推广对剂量控制要求高


CT退化从哪里来？




低剂量噪声




重构误差




稀疏视角重构



有限角重构




分辨率降低



金属伪影



环形伪影



运动伪影

01| CT成像基础与图像退化

图像退化影响的 不只是视觉质量

医学图像恢复不能只追求更干净或质量更高；在抑制噪声和伪影的同时，尽量保持真实解剖结构和临床相关信息。

成像退化 → 图像质量下降 → 病灶可见性降低
→ 分割/检测/定量误差 → 诊断与治疗决策受影响

病灶可见性下降

低对比病灶容易被噪声淹没，漏检率显著上升

削弱诊断相关信息

细小血管、骨小梁、气道分支在强噪声下被抹除或断裂

定量分析偏移

HU 值偏移影响骨密度、脂肪含量等定量测量的准确性

下游CAD性能衰减

预训练于正常剂量的分割/检测模型在低剂量输入下性能大幅下降


CONTENTS / 目录

01| CT成像基础与图像退化

02| CT图像恢复算法回顾

03| 从专用模型到通用表征

04| CT 恢复基础模型



CT噪声建模：Poisson-Gaussian采集噪声与重构传播

$$\hat{y}_k = \ln \left(\frac{I_0}{\text{Poisson}(I_0 e^{-y_k}) + n_{e,k}} \right), \quad n_{e,k} \sim \mathcal{N}(0, \sigma_e^2)$$

光子统计log-Poisson噪声

光子计数 $Y \sim \text{Poisson}(N_0 \cdot e^{-P})$ ；低剂量下方差 $\sim$ 均值，噪声与信号耦合

高光子数Gaussian近似

光子数充足时 $\text{Poisson} \approx \mathcal{N}(\mu, \mu)$ ；高剂量下可近似 Gaussian 噪声

探测器读出噪声

探测器读出加性噪声 $n_e \sim \mathcal{N}(0, \sigma_e^2)$ ；独立于信号，与 Poisson 噪声叠加形成混合模型

经过重构后，采集噪声会被放大并传播为非平稳、空间相关的图像域噪声，因此CT恢复不能简单等同于自然图像加性噪声去噪。

02| CT图像恢复算法回顾

滤波、平滑与非局部相似

依据局部平滑、边缘保持、变换域稀疏或非局部相似性抑制噪声

无需训练数据 · 容易过平滑

高斯滤波 · 中值滤波 · Non-Local Means (NLM) · BM3D · Wavelet Denoising

Article

An Image Denoising Technique Using Wavelet-Anisotropic Gaussian Filter-Based Denoising Convolutional Neural Network for CT Images

Teresa Kwamboka Abuya ^{1,*}, Richard Maina Rimiru ² and George Onyango Okeyo ²

Efficient Low-Dose CT Denoising by Locally-Consistent Non-Local Means (LC-NLM)

Michael Green¹, Edith M. Marom², Nahum Kiryati¹,
Eli Konen², and Arnaldo Mayer^{2(})

Medical Physics / Volume 46, Issue 1 / pp. 190-198

Research Article |  Full Access

Ultra-low-dose CT image denoising using modified BM3D scheme tailored to data statistics

02| CT图像恢复算法回顾

正则化与稀疏先验： 从滤波走向优化建模


将图像恢复表述为带约束的优化问题，先验正则项编码图像结构假设

先验明确 · 手工设计 · 特征不匹配可能

模型驱动恢复 = 数据一致性项 + 图像先验项：

$$x^* = \arg \min_x \{-\log p(y|x) + \beta R(x)\}$$

TV · k-SVD · Wavelet sparse regularization




Medical Physics / Volume 48, Issue 5 / pp. 2258-2270

Research Article | [Full Access](#)

Probabilistic self-learning framework for low-dose CT denoising

Ti Bai, Biling Wang, Dan Nguyen, Steve Jiang✉



02| CT图像恢复算法回顾

监督式深度学习：从LQCT到HQCT的端到端映射

利用成对的低质量与高质量CT图像训练网络，直接学习从退化图像到清晰图像的映射

配对数据依赖

RED-CNN · MAP-NN · SAGAN ·
CTFormer · WGAN-VGG

Low-Dose CT with a Residual Encoder-Decoder Convolutional Neural Network (RED-CNN)

Hu Chen, Yi Zhang*, *Member, IEEE*, Mannudeep K. Kalra, Feng Lin, Yang Chen, Peixo Liao, Jiliu Zhou, *Senior Member, IEEE*, and Ge Wang, *Fellow, IEEE*

Competitive performance of a modularized deep neural network compared to commercial algorithms for low-dose CT image reconstruction

[Hongming Shan](#), [Atul Padole](#), [Fatemeh Homayounieh](#), [Uwe Kruger](#), [Ruhani Doda Khera](#), [Chayanin Nitiwarangkul](#), [Mannudeep K. Kalra](#) ✉ & [Ge Wang](#) ✉

Sharpness-Aware Low-Dose CT Denoising Using Conditional Generative Adversarial Network

Xin Yi¹ 🌐 · Paul Babyn¹

Published online: 20 February 2018
© Society for Imaging Informatics in Medicine 2018

CTformer: Convolution-free Token2Token Dilated Vision Transformer for Low-dose CT Denoising

Dayang Wang¹, Fenglei Fan², Zhan Wu¹, Rui Liu³, Fei Wang², Hengyong Yu^{1*}

¹Department of Electrical and Computer Engineering, University of Massachusetts, Lowell, MA, USA

²Weill Cornell Medicine, Cornell University, New York City, NY, US

³3920 Mystic Valley Parkway, Medford, MA, US

02| CT图像恢复算法回顾

减少配对依赖：自监督与无监督图像恢复

利用噪声的独立性假设，或借助多次噪声观测，或依赖网络结构本身的先验，从而避免对干净参考图像的需求

计算消耗大 · 独立性假设依赖

Noise2Void · Noise2Self · zero-short
Noise2Noise · Noise2Noise · DIP

Noise2Void - Learning Denoising from Single Noisy Images

Alexander Krull^{1,2}, Tim-Oliver Buchholz², Florian Jug

¹ krull@mpi-cbg.de

² Authors contributed equally

Noise2Self: Blind Denoising by Self-Supervision

Joshua Batson^{*1} Loic Royer^{*1}

Zero-Shot Noise2Noise: Efficient Image Denoising without any Data

Youssef Mansour and Reinhard Heckel

Technical University of Munich and Munich Center for Machine Learning
Munich, Germany

y.mansour@tum.de, reinhard.heckel@tum.de

Noise2Noise: Learning Image Restoration without Clean Data

Jaakko Lehtinen^{1,2} Jacob Munkberg¹ Jon Hasselgren¹ Samuli Laine¹ Tero Karras¹ Miika Aittala³ Timo Aila¹

02| CT图像恢复算法回顾

Diffusion恢复： 强生成先验与医学安全挑战

扩散模型提供强大的高质量图像先验，但医学恢复必须处理可控性和结构真实性问题

训练推理慢 · 不确定性 · 幻觉可能

前向过程（加噪）：

$$q(x_t | x_{t-1}) = \mathcal{N}(x_t; \sqrt{1 - \beta_t} x_{t-1}, \beta_t I)$$

逆向过程（去噪生成）

$$p_\theta(x_{t-1} | x_t) = \mathcal{N}(x_{t-1}; \mu_\theta(x_t, t), \Sigma_\theta(x_t, t))$$

Denoising Diffusion Probabilistic Models

Jonathan Ho
UC Berkeley

Ajay Jain
UC Berkeley

Pieter Abbeel
UC Berkeley

Image Super-Resolution via Iterative Refinement

Chitwan Saharia,[†] Jonathan Ho, William Chan, Tim Salimans, David J. Fleet, Mohammad Norouzi
{sahariac, jonathanho, williamchan, salimans, davidfleet, mnorouzi}@google.com
Google Research, Brain Team

Medical Physics / Volume 52, Issue 1 / pp. 329-345

RESEARCH ARTICLE | [Full Access](#)

Diffusion probabilistic priors for zero-shot low-dose CT image denoising

Xuan Liu, Yaoqin Xie, Chenbin Liu, Jun Cheng, Songhui Diao, Shan Tan, Xiaokun Liang✉

Low-Dose CT Using Denoising Diffusion Probabilistic Model for 20× Speedup

Wenjun Xia, Qing Lyu, Ge Wang
Department of Biomedical Engineering
Rensselaer Polytechnic Institute
Troy, NY 12180 USA
{xiaw4, lyuq, wangg6}@rpi.edu

02| CT图像恢复算法回顾

迭代重建与MBIR： 基于投影数据的重建

直接建模投影数据、将成像几何、噪声统计与图像先验统一纳入重建过程，在物理一致性和结构保真方面通常更具优势

物理一致性强 · 伪投影模拟存在误差 · 计算成本高

MBIR 目标函数：

$$x^* = \arg \min_x \{-\log p(y|x) + \beta R(x)\}$$

$$x^* = \arg \min_x \left\{ \frac{1}{2} \|y - Ax\|_{\rho}^2 + \beta R(x) \right\}$$

Medical Physics / Volume 39, Issue 9 / pp. 5520-5531

Radiation imaging physics | [Full Access](#)

Characterization of adaptive statistical iterative reconstruction algorithm for dose reduction in CT: A pediatric oncology perspective

S. L. Brady, B. S. Yee, R. A. Kaufman

PAPER • OPEN ACCESS

Computed tomography reconstruction using deep image prior and learned reconstruction methods

Daniel Otero Baguer, Johannes Leuschner and Maximilian Schmidt

Published 2 September 2020 • © 2020 The Author(s). Published by IOP Publishing Ltd

MAGIC: Manifold and Graph Integrative Convolutional Network for Low-Dose CT Reconstruction

Wenjun Xia[✉], Graduate Student Member, IEEE, Zexin Lu, Yongqiang Huang, Zuoqiang Shi[✉], Yan Liu[✉], Member, IEEE, Hu Chen[✉], Yang Chen[✉], Senior Member, IEEE, Jiliu Zhou, Senior Member, IEEE, and Yi Zhang[✉], Senior Member, IEEE

Wavelet-Improved Score-Based Generative Model for Medical Imaging

Weiwen Wu[✉], Member, IEEE, Yanyang Wang[✉], Qiegen Liu[✉], Senior Member, IEEE, Ge Wang[✉], Fellow, IEEE, and Jianjia Zhang[✉]

CT恢复方法的范式比较

方法类型	数据需求	是否需要原始投影	运行速度	核心局限
经典滤波	无需训练	否	较快	过平滑，复杂退化适应差
正则化先验	无需训练	否	一般	手工先验强，参数敏感，细节易过平滑
自监督&无监督方法	无需干净图像	否	较慢	无需干净图像，需噪声模型/独立性假设
有监督方法	配对或伪配对数据	否	较快	退化/数据集依赖强，跨剂量/设备/协议泛化受限
扩散模型	可配对或非配对	否	较慢	训练成本高，图像幻觉风险，医学安全存疑
模型驱动迭代重建	无需训练	是	较慢	计算成本高，需要投影数据和系统建模
深度双域/物理约束网络	配对数据	是	较慢	计算成本高，需要投影数据和系统建模


CONTENTS / 目录

01| CT成像基础与图像退化

02| CT图像恢复算法回顾

03| 从专用模型到通用表征

04| CT恢复基础模型



03| 从专用模型到通用表征

什么是基础模型

基础模型是在大规模、多样化数据上预训练得到的通用模型，能够学习可迁移的表征或生成先验，并通过任务头、prompt、微调或参数高效适配迁移到多种下游任务。

大规模

预训练

在海量数据上学习通用表征或先验

通用表征

从单一任务特征转向可迁移的底层能力

多任务

迁移

同一预训练底座支持分类、分割、检测、恢复等任务

灵活适配

通过linear probing、Adapter、LoRA或全量微调适配新任务

数据效率

减少下游任务对大规模标注数据的依赖


范式转变

从“每个任务独立训练”转向“预训练底座+下游适配”



03| 从专用模型到通用表征

Foundation Model 的预训练范式



图像判别式自监督

代表: SimCLR、MoCo、DINO

核心: 通过增强视图、一致性学习或自蒸馏, 让模型学习图像语义表征。

生成式/重建式自监督

代表: MAE、BEiT、iBOT

核心: 遮挡图像patch, 让模型从可见部分恢复缺失内容, 学习结构和上下文。

视觉-语言对齐预训练

代表: CLIP、ALIGN、BLIP

核心: 利用图像-文本配对数据, 把视觉特征和语言语义映射到同一表示空间。

03| 从专用模型到通用表征

四种下游任务适配范式

Zero-shot

不更新模型参数，只通过prompt、任务描述、示例来让模型完成任务。

轻量任务头

backbone主体不动，只训练一个线性层或者轻量decoder作为task-specific head。

参数高效微调


利用LoRA、Adapter等更新少量新增参数或低秩参数。

全量微调

更新 foundation model 的全部或大部分参数，使其针对特定任务、领域或指令分布适配。

03| 从专用模型到通用表征

减少从零训练，降低数据与标注成本



数据成本高

医学影像标注审阅成本高，需要专家、时间和一致性控制

任务样本少

罕见病、特殊协议、新设备、新部位等数据来源有限

更好的初始化

预训练提供更好的参数初始化，减少从零学习的需求

轻量任务适配


降低下游任务的数据和计算成本

Foundation model把昂贵的学习过程前移到预训练阶段，下游任务只需低成本适配。

03| 从专用模型到通用表征

大规模预训练带来更稳健的泛化


Task-specific model



narrow representation

vs.

Foundation model



generalized representation

多数据源预训练

减少对单一数据集、医院或单一协议的依赖。

自监督学习

利用未标注数据中的结构信息。

跨任务迁移

不同任务共享底层视觉和解剖表征。


数据要求相对较低

小样本与跨域场景中优势更明显。

通过更大、更丰富的数据分布学习表征，因此更容易迁移到未见过的数据和任务。

03| 从专用模型到通用表征

规模化预训练可能带来涌现能力



模型在足够大规模预训练后，表现出超出单一训练任务的迁移和组合能力。

03| 从专用模型到通用表征

从专有模型走向CT 恢复基础模型

训练范式的根本转变

专用模型 • Task-Specific

多类退化问题单独训练

配对数据获取困难

依赖模拟退化模型

泛化能力有限

真实退化场景不适配

基础模型 • Foundation Model

统一预训练主干

通用恢复底座

多任务适配接口

可迁移图像结构与恢复先验

泛用迁移能力强


CONTENTS / 目录

01| CT成像基础与图像退化


02| CT图像恢复算法回顾

03| 从专用模型到通用表征

04| CT 恢复基础模型



04| UniFMIR: 把基础模型引入图像恢复



Multi-head: 不同恢复任务使用各自的任务专用输入接口，适配异质输入


共享backbone: 所有任务共享同一特征提取模块，学习通用恢复表征

Multi-tail: 不同任务使用各自输出接口，输出格式不强行统一

预训练的作用: backbone 学习 $LQ \rightarrow HQ$ 通用方向，下游任务微调只需适配 head / tail


Ma, C., Tan, W., He, R. et al. Pretraining a foundation model for generalizable fluorescence microscopy-based image restoration. *Nat Methods* 21, 1558–1567 (2024).

04| UniFMIR: 把基础模型引入图像恢复




04| UniFMIR: 把基础模型引入图像恢复

Super-resolution





Denoise




04| UniFMIR: 把基础模型引入图像恢复

Isotropic
Reconstruct



Volumetric
Reconstruct



04| UniFMIR: 把基础模型引入图像恢复

UniFMIR给Restoration FM的三个启发

预训练恢复底座

恢复基础模型可以首先理解为一个预训练的restoration backbone, 学习可迁移的图像结构先验与恢复表征, 而不是只服务单一退化任务。

一个预训练好的恢复底座, 下游任务不必从零学习恢复方向。

下游任务接口分离

多任务统一不等于强制相同输入输出。UniFMIR保留任务专用的head/tail, 把共性的结构恢复能力集中在共享的backbone中。

任务差异由head/tail吸收, 共性能力由共享的backbone承载。

通用恢复范式

不同恢复任务都可抽象为从LQ 到HQ的映射。预训练学习的是真实结构先验, 非固定任务接口。

预训练学习跨任务共享的结构先验与恢复方向, 而非退化的专用逆映射。

04| TAMP: CT场景中的物理驱动基础模型


Non-ideal CT (NICT) 包含三类典型退化

低剂量CT



低剂量噪声。管电流降低导致量子噪声增强，表现为弥漫性结构噪声，细粒度噪声在全图范围内增强。

稀疏角CT



稀疏角采集伪影。角度采样不足导致条纹状伪影，沿固定方向延伸，破坏软组织边界和血管连续性。

有限角CT




有限角扫描。投影角范围受限，导致部分 Radon 空间信息缺失，造成大尺度结构模糊和软组织信息丢失。

传统路线：为每类 NICT 分别收集数据、设计网络、训练模型。
TAMP：把这些问题统一定义为NICT增强问题。


Ge, R., Liu, Y., Wu, Z. et al. Imaging foundation model for universal enhancement of non-ideal measurement CT. *Nat Commun* (2026).

04| TAMP: CT场景中的物理驱动基础模型

如果退化能够用CT物理过程近似模拟，那么就可以利用物理模拟构建大规模预训练数据，让模型先学习一个跨退化、跨部位的通用增强先验。



04| TAMP: CT场景中的物理驱动基础模型



04| TAMP: CT场景中的物理驱动基础模型

物理驱动模拟：把CT物理变成大规模预训练数据

10.8M对

simulated NICT images用于预训练



3.6M张

NICT-ICT image pairs构成SimNICT


27个benchmark任务

NICT tasks = 3 types $\times$ 3 body regions $\times$ 3 degrees


→ 无需人工采集真实配对；从 ICT 直接物理模拟各类退化
→ 覆盖 head / chest / abdomen / lower-limbs 四个体位
→ LDCT 通过投影域噪声模拟低剂量测量，SVCT / LACT 通过稀疏角/有限角重建



04| TAMP: CT场景中的物理驱动基础模型




04| TAMP: CT场景中的物理驱动基础模型



04| TAMP: CT场景中的物理驱动基础模型

5张切片即可构建专用增强模型



5 slices: 仅用 5 张目标场景slice作为适配数据

LoRA fine-tuning: 冻结主干，只更新低秩适配矩阵，参数量极少

TAMP-S 显著优于 zero-shot TAMP，说明适配本身是有效的

TAMP-S 在多数任务上超越从零训练的专用模型 (RED-CNN、FBPCNN 等)

RED-CNN / FBPCNN: 需要数百张标注片子从零收敛。


TAMP-S: 预训练初始化已具备恢复能力，适配只需微调方向。

04| TAMP: CT场景中的物理驱动基础模型

d


Metrics	RED-CNN	WGAN-VGG	FBPConvNet	SPECIAL	TransCT	MITNet	ProCT	TAMP (Ours)	TAMP-S (Ours)
PSNR(dB)↑	43.23±1.07	40.54±0.97	44.09±1.21	45.12±1.18	42.61±0.97	42.95±0.92	41.99±0.89	<u>45.58±1.15</u>	47.01±1.32
SSIM(%)↑	90.9±2.26	83.85±3.18	93.13±1.53	95.45±1.26	92.27±1.68	92.79±1.35	90.52±1.88	<u>96.51±0.89</u>	97.55±0.65
RMSE(Hu)↓	32.57±3.70	40.62±3.74	30.55±3.58	25.48±3.19	32.9±3.41	31.25±3.05	37.3±3.43	<u>24.21±2.94</u>	20.21±2.83
LPIPS(%)↓	10.69±2.75	15.19±3.16	9.47±2.54	7.66±2.32	11.55±2.98	12.92±3.32	13.8±4.98	<u>5.08±2.00</u>	4.57±1.52

This table presents the average performance of each method across 27 NICT enhancement tasks, with the details provided in the supplementary materials.



04| TAMP: CT场景中的物理驱动基础模型

临床接受度：不只看图像质量指标



→ PCA (Probability of Clinical Acceptability): 不只关注 PSNR 或 SSIM 是否最高, 而是增强后的图像是否更接近临床可用

→ TAMP 和 TAMP-S 在主观图像质量和临床接受度上显著优于传统方法

→ 评价标准不能只停留在像素误差, 还要看结构是否可信、图像是否真正支持临床判断

Zero-shot TAMP 在真实扫描器上具有迁移能力; TAMP-S 适配后进一步提升。说明物理驱动模拟的 sim-to-real gap 可通过少量适配得到缓解。

04| TAMP: CT场景中的物理驱动基础模型

CT 物理 + 基础模型范式: TAMP 的核心贡献

统一问题定义

将低剂量、有限角和稀疏角CT统一纳入非理想CT增强框架, 使多类非理想成像问题被视作一个基础模型可以统一学习的任务

物理驱动大规模预训练

借助CT物理模拟构建大规模预训练数据, 使得基础模型在CT恢复场景中的训练成为可能

通用增强 + 高效适配

zero-shot通用增强和少量数据适配两个维度上都表现出可行性, 能够有效降低下游专用模型的开发成


物理模拟退化与真实扫描仍存在差异。真实临床退化受设备型号、重建算法、运动伪影以及协议设置等多重因素影响, 难以被预设的退化模型完整刻画。

真实退化不能被参数化模型预定义时, 怎么办?

04| HorusEye: 从真实数据中学习Tomography退化

结构层间连续，退化层间不连续


Structure • 解剖结构



解剖结构在 z 轴上缓慢变化，相邻切片的结构轮廓、组织边界高度相似，**结构连续**。

中间切片 z 可以用相邻切片 $z-1$ 和 $z+1$ 预测，预测误差主要来自噪声，而非结构差异。

Noise • 扫描噪声



X 射线采集的量子噪声在额切片特定的退化相对独立随机，与相邻切片相关性更弱，**噪声不连续**。

预测切片 z 与真实切片 z 的残差主要包含 slice-specific 噪声。

Yuetan Chu, Longxi Zhou, Gongning Luo, et al. HorusEye: A self-supervised foundation model for generalizable X-ray tomography restoration. *Nature Computational Science* 2026

04| HorusEye：从真实数据中学习Tomography退化

相邻切片之间结构与噪声的相关性分析

Metric	Original slice	Denosed slice	Self-extracted noise	Log-Poisson noise
PCC	0.905±0.096	0.926±0.278	0.065±0.194	0.043±0.062
SCC	0.868±0.007	0.975±0.009	0.059±0.173	0.008±0.057
MI	1.417±0.385	2.537±0.209	0.117±0.067	0.046±0.016
Kendall's Tau	0.774±0.103	0.886±0.025	0.111±0.098	0.028±0.017


Supplementary Table 1. Quantitative validation of contrastive inter-slice continuity between structural information and noise. A higher value of all metrics suggests higher dependence and correlation.

Metric	Self-extracted noise	Log-Poisson noise	Gaussian noise
<i>l</i> -MI	0.215±0.076	0.096±0.028	0.051±0.000
Corr _{GLCM}	0.301±0.127	0.187±0.005	0.000±0.002

Supplementary Table 2. Quantitative validation of intra-slice dependence and correlation of noise. A higher value of all metrics suggests higher dependence and correlation.

04| HorusEye: 从真实数据中学习Tomography退化

层间预测驱动的真实噪声自提取与恢复学习




Stage 1

基于层间预测提取真实噪声

相邻切片预测中间切片，预测值为结构估计；原始切片与预测切片之差可反映slice-specific noise.

$$x_h^p = H_E(x_{h-1}, x_{h+1}) \rightarrow x_h$$

$$x_h^p = H_E(n_{-1} \odot x_{h-1}, n_1 \odot x_{h+1})$$



Stage 2

真实退化用于恢复模型训练


将提取的真实噪声注入干净集，训练 SwinUNet 去噪自编码器，学习真实 noise $\rightarrow$ clean 映射。

$$\{x_{h-1}^N, x_h^N, x_{h+1}^N\} = \{n_{-1}^E \odot x_{h-1}^C, n_0^E \odot x_h^C, n_1^E \odot x_{h+1}^C\}$$


$$\hat{x}_h^C = H_D(\{x_{h-1}^N, x_h^N, x_{h+1}^N\})$$

04| HorusEye: 从真实数据中学习Tomography退化

双向正反馈协同优化



04| HorusEye: 从真实数据中学习Tomography退化



04| HorusEye: 从真实数据中学习Tomography退化

大规模多模态真实世界数据预训练

100M+ slices

images (2D slices total)


120K+ volumes

volumes (3D tomography volumes)



50个多模态数据集

datasets from public + private sources


- Medical CT (头/胸/腹/骨骼)
- Micro-CT (材料、生物组织)
- Phase-contrast tomography
- Nano-CT、Ptychography等




04| HorusEye: 从真实数据中学习Tomography退化 剂量对比数据




- LDCT → restoration
→ compare with HDCT
- 模具/猪扫描提供配对参考
- 验证恢复结果是否接近高剂量图像




04| HorusEye: 从真实数据中学习Tomography退化 真实世界数据验证




04| HorusEye: 从真实数据中学习Tomography退化




MSD chest dataset




In-house CT chest dataset (Harbin, China)




LIDC-IDRI chest dataset




In-house COVID-19 dataset (Mudanjiang, China)




KiTS abdomen dataset



TCIA CT Colonography dataset




TCIA Hepatocellular carcinoma dataset




Spineweb dataset



04| HorusEye: 从真实数据中学习Tomography退化 物理模拟低剂量数据




04| HorusEye: 从真实数据中学习Tomography退化 固定预训练Encoder, 迁移到四种恢复任务




04| HorusEye: 从真实数据中学习Tomography退化




04| HorusEye: 从真实数据中学习Tomography退化 跨模态泛化能力：不仅是medical CT



04| HorusEye: 从真实数据中学习Tomography退化 跨模态泛化能力：不仅是medical CT




04| HorusEye: 从真实数据中学习Tomography退化 临床价值：恢复结果是否帮助读片？




04| HorusEye：从真实数据中学习Tomography退化

Scanning region	Task	Network models	Metric	Raw data	Restored data	Improvement
Chest	Airway segmentation	SwinUNet	DSC(%)	82.2±3.7	86.2±4.2	4.0
		nnUNet		84.8±4.1	89.4±3.7	4.6
	Vein segmentation	SwinUNet	DSC(%)	68.3±4.7	82.6±5.2	14.3
		nnUNet		72.4±4.3	87.4±6.9	15.0
		SwinUNet	BD(%)	45.1±11.4	66.7±10.2	21.6
		nnUNet		46.2±13.3	72.8±9.9	26.6
	Artery segmentation	SwinUNet	DSC(%)	67.9±7.4	84.8±4.4	16.9
		nnUNet		70.9±7.2	88.0±6.6	17.1
		SwinUNet	BD(%)	47.5±12.0	72.1±9.2	24.6
		nnUNet		49.6±11.5	75.3±9.1	25.7
	Heart segmentation	SwinUNet	DSC(%)	89.4±5.9	90.3±4.6	0.9
		nnUNet		91.1±3.2	91.4±4.3	0.3
	Pneumonia segmentation	SwinUNet		72.7±10.3	73.2±10.8	0.5
		nnUNet		73.2±9.76	74.1±8.5	0.9
	Lung cancer segmentation	SwinUNet		84.0±8.9	85.5±7.5	1.5
		nnUNet		86.0±5.7	86.2±6.8	0.2
	Inter-patient registration	VoxelMorph		86.7±6.9	88.0±6.5	1.3
	Intra-patient registration	VoxelMorph		75.8±10.2	76.0±9.8	0.2
	Lung cancer classification	2DCNN	ACC(%)	90.4	93.7	3.4
		SwinTransformer		92.0	92.0	0.0
	Lung pneumonia classification	2DCNN		87.5	89.0	1.5
		SwinTransformer		90.5	91.0	0.5

04| HorusEye: 从真实数据中学习Tomography退化 基础模型助力真实退化分析



04| HorusEye: 从真实数据中学习Tomography退化



04| HorusEye：从真实数据中学习Tomography退化

真实退化自监督学习驱动的通用恢复

大规模自监督学习

100M+tomography图像大规模预训练；不预设退化模型，不依赖配对数据或投影数据，而是直接从真实数据中学习图像恢复

通用恢复 + 临床验证

借助基础模型的大规模预训练范式，在多样化的数据源和多模态成像数据上学习复杂的真实退化分布

真实退化建模能力

预训练学习的不是某个特定退化的逆过程，而是真实结构先验与退化行为，使模型具备从真实数据中分离并建模退化成分的能力

训练稳定性有限：双向正反馈协同优化依赖多阶段迭代，噪声集与干净集的同步更新增加了工程复杂度和训练不确定性。

恢复—保真权衡仍需调节：不预设退化模型，图像恢复与结构保留之间缺少显式物理约束，需要任务相关的经验设计。

细微结构易被过平滑：真实高频结构可能与噪声模态混淆，导致骨小梁等高频结构被误抑制或过度平滑。

Raw image



CTFormer



HorusEye



04| CT 恢复基础模型

UniFMIR · TAMP · HorusEye

Summary · 三条互补路线

UniFMIR · 范式

Multi-task Restoration Backbone

预训练共享 backbone, head/tail 适配不同任务。回答: Restoration FM 是什么?

TAMP · CT 物理

Physics-driven CT Pretraining

SimNICT 大规模物理模拟, 通用恢复+高效适配。回答: 基于模拟的恢复方法如何适配基础模型?

HorusEye · 真实退化

Self-supervised Real Degradation

真实世界数据作为自监督信号, 显示出跨模态、任务的迁移性。回答: 如何直接学习真实退化?

Restoration FM通过预训练获得更好的初始化, 从而提升恢复性能、跨域泛化能力和低成本适配效率。它区别于专用模型的根本在于: 不是只学习某一种退化的逆映射, 而是学习真实结构信息与通用恢复先验。

04| Restoration FM近期其他代表性工作

nature biomedical engineering

Article

<https://doi.org/10.1038/s41551-024-01283-7>

A foundation model for enhancing magnetic resonance images and downstream segmentation, registration and diagnostic tasks

Received: 2 August 2023
Accepted: 17 October 2024
Published online: 5 December 2024

Yue Sun^{1,2}, Limei Wang^{1,3}, Gang Li^{1,3}, Weili Lin^{1,3} & Li Wang^{1,2}

In structural magnetic resonance (MR) imaging, motion artefacts, low resolution, imaging noise and variability in acquisition protocols frequently degrade image quality and confound downstream analyses. Here we report a foundation model for the motion correction, resolution enhancement, denoising and harmonization of MR images. Specifically, we trained a tissue-classification neural network to predict tissue labels, which are then leveraged by a 'tissue-aware' enhancement network to generate high-quality MR images. We validated the model's effectiveness on a large and diverse dataset comprising 2,448 deliberately corrupted images and 10,963 images spanning a wide age range (from fetuses to elderly individuals) acquired using a variety of clinical scanners across 19 public datasets. The model consistently outperformed state-of-the-art algorithms in improving the quality of MR images, handling pathological brains with multiple sclerosis or gliomas, generating 7-T-like images from 3-T scans and harmonizing images acquired from different scanners. The high-quality, high-resolution and harmonized images generated by the model can be used to enhance the performance of models for tissue segmentation, registration, diagnosis and other downstream tasks.

a **b** **c**

d

e

f

g

h

i

j

k

l

m

n

o

p

q

r

s

t

u

v

w

x

y

z

aa

ab

ac

ad

ae

af

ag

ah

ai

aj

ak

al

am

an

ao

ap

aq

ar

as

at

au

av

aw

ax

ay

az

ba

bb

bc

bd

be

bf

bg

bh

bi

bj

bk

bl

bm

bn

bo

bp

bq

br

bs

bt

bu

bv

bw

bx

by

bz

ca

cb

cc

cd

ce

cf

cg

ch

ci

cj

ck

cl

cm

cn

co

cp

cq

cr

cs

ct

cu

cv

cw

cx

cy

cz

da

db

dc

dd

de

df

dg

dh

di

dj

dk

dl

dm

dn

do

dp

dq

dr

ds

dt

du

dv

dw

dx

dy

dz

ea

eb

ec

ed

ee

ef

eg

eh

ei

ej

ek

el

em

en

eo

ep

eq

er

es

et

eu

ev

ew

ex

ey

ez

fa

fb

fc

fd

fe

ff

fg

fh

fi

fj

fk

fl

fm

fn

fo

fp

fq

fr

fs

ft

fu

fv

fw

fx

fy

fz

ga

gb

gc

gd

ge

gf

gg

gh

gi

gj

gk

gl

gm

gn

go

gp

gq

gr

gs

gt

gu

gv

gw

gx

gy

gz

ha

hb

hc

hd

he

hf

hg

hh

hi

hj

hk

hl

hm

hn

ho

hp

hq

hr

hs

ht

hu

hv

hw

hx

hy

hz

ia

ib

ic

id

ie

if

ig

ih

ii

ij

ik

il

im

in

io

ip

iq

ir

is

it

iu

iv

iw

ix

iy

iz

ja

jb

jc

jd

je

jf

jj

jk

jl

jm

jn

jo

jp

jq

jr

js

jt

ju

jv

jw

jx

jy

jz

ka

kb

kc

kd

ke

kf

kg

kh

ki

kj

kk

kl

km

kn

ko

kp

kq

kr

ks

kt

ku

kv

kw

kx

ky

kz

la

lb

lc

ld

le

lf

lg

lh

li

lj

lk

ll

lm

ln

lo

lp

lq

lr

ls

lt

lu

lv

lw

lx

ly

lz

ma

mb

mc

md

me

mf

mg

mh

mi

mj

mk

ml

mm

mn

mo

mp

mq

mr

ms

mt

mu

mv

mw

mx

my

mz

na

nb

nc

nd

ne

nf

ng

nh

ni

nj

nk

nl

nm

nn

no

np

nq

nr

ns

nt

nu

nv

nw

nx

ny

nz

oa

ob

oc

od

oe

of

og

oh

oi

oj

ok

ol

om

on

oo

op

oq

or

os

ot

ou

ov

ow

ox

oy

oz

pa

pb

pc

pd

pe

pf

pg

ph

pi

pj

pk

pl

pm

pn

po

pp

pq

pr

ps

pt

pu

pv

pw

px

py

pz

qa

qb

qc

qd

qe

qf

qg

qh

qi

qj

qk

ql

qm

qn

qo

qp

qq

qr

qs

qt

qu

qv

qw

qx

qy

qz

ra

rb

rc

rd

re

rf

rg

rh

ri

rj

rk

rl

rm

rn

ro

rp

rq

rr

rs

rt

ru

rv

rw

rx

ry

rz

sa

sb

sc

sd

se

sf

sg

sh

si

sj

sk

sl

sm

sn

so

sp

sq

sr

ss

st

su

sv

sw

sx

sy

sz

ta

tb

tc

td

te

tf

tg

th

ti

tj

tk

tl

tm

tn

to

tp

tq

tr

ts

tt

tu

tv

tw

tx

ty

tz

ua

ub

uc

ud

ue

uf

ug

uh

ui

uj

uk

ul

um

un

uo

up

uq

ur

us

ut

uu

uv

uw

ux

uy

uz

va

vb

vc

vd

ve

vf

vg

vh

vi

vj

vk

vl

vm

vn

vo

vp

vq

vr

vs

vt

vu

vv

vw

vx

vy

vz

wa

wb

wc

wd

we

wf

wg

wh

wi

wj

wk

wl

wm

wn

wo

wp

wq

wr

ws

wt

wu

wv

ww

wx

wy

wz

xa

xb

xc

xd

xe

xf

xg

xh

xi

xj

xk

xl

xm

xn

xo

xp

xq

xr

xs

xt

xu

xv

xw

xx

xy

xz

ya

yb

yc

yd

ye

yf

yg

yh

yi

yj

yk

yl

ym

yn

yo

yp

yq

yr

ys

yt

yu

yv

yw

yx

yy

yz

za

zb

zc

zd

ze

zf

zg

zh

zi

zj

zk

zl

zm

zn

zo

zp

zq

zr

zs

zt

zu

zv

zw

zx

zy

zz

aa

ab

ac

ad

ae

af

ag

ah

ai

aj

ak

al

am

an

ao

ap

aq

ar

as

at

au

av

aw

ax

ay

az

ba

bb

bc

bd

be

bf

bg

bh

bi

bj

bk

bl

bm

bn

bo

bp

bq

br

bs

bt

bu

bv

bw

bx

by

bz

ca

cb

cc

cd

ce

cf

cg

ch

ci

cj

ck

cl

cm

cn

co

cp

cq

cr

cs

ct

cu

cv

cw

cx

cy

cz

da

db

dc

dd

de

df

dg

dh

di

dj

dk

dl

dm

dn

do

dp

dq

dr

ds

dt

du

dv

dw

dx

dy

dz

ea

eb

ec

ed

ee

ef

eg

eh

ei

ej

ek

el

em

en

eo

ep

eq

er

es

et

eu

ev

ew

ex

ey

ez

fa

fb

fc

fd

fe

ff

fg

fh

fi

fj

fk

fl

fm

fn

fo

fp

fq

fr

fs

ft

fu

fv

fw

fx

fy

fz

ga

gb

gc

gd

ge

gf

gg

gh

gi

gj

gk

gl

gm

gn

go

gp

gq

gr

gs

gt

gu

gv

gw

gx

gy

gz

ha

hb

hc

hd

he

hf

hg

hh

hi

hj

hk

hl

hm

hn

ho

hp

hq

hr

hs

ht

hu

hv

hw

hx

hy

hz

ia

ib

ic

id

ie

if

ig

ih

ii

ij

ik

il

im

in

io

ip

iq

ir

is

it

iu

iv

iw

ix

iy

iz

ja

jb

jc

jd

je

jf

jj

jk

jl

jm

jn

jo

jp

jq

jr

js

jt

ju

jv

jw

jx

jy

jz

ka

kb

kc

kd

ke

kf

kg

kh

ki

kj

kk

kl

km

kn

ko

kp

kq

kr

ks

kt

ku

kv

kw

kx

ky

kz

la

lb

lc

ld

le

lf

lg

lh

li

lj

lk

ll

lm

ln

lo

lp

lq

lr

ls

lt

lu

lv

lw

lx

ly

lz

ma

mb

mc

md

me

mf

mg

mh

mi

mj

mk

ml

mm

mn

mo

mp

mq

mr

ms

mt

mu

mv

mw

mx

my

mz

na

nb

nc

nd

ne

nf

ng

nh

ni

nj

nk

nl

nm

nn

no

np

nq

nr

ns

nt

nu

nv

nw

nx

ny

nz

oa

ob

oc

od

oe

of

og

oh

oi

oj

ok

ol

om

on

oo

op

oq

or

os

ot

ou

ov

ow

ox

oy

oz

pa

pb

pc

pd

pe

pf

pg

ph

pi

pj

pk

pl

pm

pn

po

pp

pq

pr

ps

pt

pu

pv

pw

px

py

pz

qa

qb

qc

qd

qe

qf

qg

qh

qi

qj

qk

ql

qm

qn

qo

qp

qq

qr

qs

qt

qu

qv

qw

qx

qy

qz

ra

rb

rc

rd

re

rf

rg

rh

ri

rj

rk

rl

rm

rn

ro

rp

rq

rr

rs

rt

ru

rv

rw

rx

ry

rz

sa

sb

sc

sd

se

sf

sg

sh

si

sj

sk

sl

sm

sn

so

sp

sq

sr

ss

st

su

sv

恢复专有模型

- 面向单一退化或特定任务
- 学习特定退化逆过程、LQ→HQ映射
- 依赖特定数据集、协议或模拟数据
- 真实世界泛化有限
- 容易过拟合训练退化
- 新场景通常需要从头训练
- 多以PSNR、SSIM等指标为主

恢复基础模型

- 面向多退化、多任务的通用恢复
- 学习可迁移的结构和通用恢复表征
- 大规模预训练数据初始化
- 性能一般好于专有模型
- 容易过拟合训练退化
- 通过微调或任务头适配
- 更强调临床和下游任务收益

04| 医学恢复基础模型

01

多任务统一

把多个相关任务放到同一个问题定义下，从单一退化/单一任务走向多退化、多场景的统一建模。

02

真实数据分布

数据要尽可能覆盖真实部署中的各种场景，包括设备、协议、部位、模态、剂量、退化类型和任务场景。

03

引入领域先验

不能只依赖通用视觉表征；把成像物理、解剖结构、协议信息和临床任务转化为可学习的预训练信号。

04

低成本适配

不只是zero-shot，而是让新场景不必从零训练，通过微调或轻量模块实现更快、更省数据的临床适配。

05

临床信息保真

不能只证明图像变清楚，还要验证真实临床信息是否被保留、是否产生幻觉，是否真正支持读片和下游任务。

06

FM学习范式

引导模型不是只学习某一种退化的逆映射，而是学习真实结构信息与通用恢复先验。

CONCLUSION / 总结

01| CT成像基础与图像退化

02| CT图像恢复算法回顾

03| 从专用模型到通用表征

04| CT 恢复基础模型



不是只学习某一种退化的逆映射，而是学习真实结构信息与通用恢复先验。

谢谢聆听！

Question & Discussion

